

1 Wstęp

Celem zadania jest zademonstrowanie techniki **Supermodelowania** w kontekście asymilacji danych. Metoda ta polega na sprzęgnięciu ze sobą kilku niedoskonałych modeli, aby stworzyć jeden „supermodel”, który odwzorowuje rzeczywistość lepiej niż którykolwiek z modeli składowych z osobna.

Zamiast klasycznego uśredniania wyników (Ensemble Averaging), supermodelowanie pozwala modelom wymieniać informacje w trakcie symulacji, co zapobiega szybkiej dywergencji trajektorii w układach chaotycznych.

2 Wybrany Model: Łańcuch Pokarmowy Hastingsa-Powella

Jako model bazowy wybrałem układ równań różniczkowych Hastingsa-Powella (1991). Model ten opisuje dynamikę nieliniowego łańcucha pokarmowego składającego się z trzech populacji. Jest to układ wykazujący zachowania chaotyczne, co czyni go doskonałym kandydatem do testowania algorytmów predykcji.

Zmienne stanu:

- x : Roślinność (zasób podstawowy)
- y : Roślinożercy (konsumują x)
- z : Drapieżnicy (konsumują y)

Układ równań (ODE):

$$\begin{aligned}\frac{dx}{dt} &= x(1-x) - \frac{a_1xy}{1+b_1x} \\ \frac{dy}{dt} &= \frac{a_1xy}{1+b_1x} - \frac{a_2yz}{1+b_2y} - d_1y \\ \frac{dz}{dt} &= \frac{a_2yz}{1+b_2y} - d_2z\end{aligned}\tag{1}$$

Gdzie parametry a_i, b_i odpowiadają za stopy drapieżnictwa i nasycenia, a d_i za śmiertelność.

3 Metodyka i Implementacja

3.1 Generowanie Rzeczywistości (Ground Truth)

W symulacji przyjąłem zestaw parametrów ($a_1 = 5.0, b_1 = 3.0, \dots$), dla których generowana jest trajektoria referencyjna. Z tej trajektorii pobierane są próbki treningowe.

3.2 Modele Surogatowe i Pre-trening

Stworzyłem trzy modele surogatowe, symulujące sytuację, w której nasza wiedza o świecie jest niepełna. Każdy z modeli posiada zaburzone parametry (np. zawyżoną śmiertelność lub zaniżoną stopę drapieżnictwa).

- **Scenariusz Krótki (Short Pre-training):** Modele są słabo wytrenowane, błędy parametrów są duże (około $\pm 20\%$).
- **Scenariusz Średni (Medium Pre-training):** Modele są lepiej dopasowane, błędy parametrów są mniejsze (około $\pm 5\%$).

3.3 Budowa Supermodelu

Modele składowe (M_1, M_2, M_3) połączyłem sprzężeniem typu *Nudging* do średniej stanu. Dynamika i -tego modelu w supermodelu wyraża się wzorem:

$$\dot{\mathbf{x}}_i = F_i(\mathbf{x}_i) + C \cdot (\bar{\mathbf{x}} - \mathbf{x}_i) \quad (2)$$

Gdzie $\bar{\mathbf{x}}$ to średnia stanu wszystkich modeli, a C to macierz współczynników sprzężenia. Wartość C jest optymalizowana w fazie treningowej tak, aby zminimalizować błąd względem danych historycznych.

4 Oczekiwane Zachowanie

W układach chaotycznych (jak Hastings-Powell), nawet mały błąd parametru powoduje wykładniczą rozbieżność trajektorii. Oczekujemy, że:

1. Modele surogatowe szybko zbiegną z właściwej orbity atraktora (np. przewidzą wymarcie populacji lub eksplozję, która nie nastąpi).
2. Supermodel, dzięki sprzężeniu C , utrzyma trajektorię zbliżoną do rzeczywistej znacznie dłużej, korygując wzajemnie błędy poszczególnych pod-modeli.

5 Wyniki Eksperymentu

Poniższe wykresy prezentują wyniki działania zaimplementowanego algorytmu w języku Python.

5.1 Wizualizacja Trajektorii w Przestrzeni Fazowej (3D)

Na wykresie 3D (Rys. 1) przedstawiono trajektorie w fazie predykcji. Czarna linia reprezentuje Rzeczywistość. Linie przerywane to modele pojedyncze, które szybko ulegają dywergencji. Linia magenta to Supermodel, który skutecznie podąża za trajektorią rzeczywistą.




Figure 1: Porównanie trajektorii w przestrzeni fazowej 3D (Vegetation-Herbivore-Predator). Supermodel vs Modele Surogatowe.

5.2 Wpływ Czasu Treningu na Jakość Predykcji

Wykres błędu w czasie (Rys. 2) pokazuje, jak jakość modeli składowych wpływa na supermodel.

- **Linia Czerwona (Short Training):** Błąd rośnie szybko. Sprężenie nie jest w stanie skompensować dużych błędów parametrów.
- **Linia Zielona (Medium Training):** Błąd utrzymuje się na niskim poziomie przez długi czas. Lepsze modele składowe pozwalają supermodelowi na bardzo dokładną predykcję długoterminową.




Figure 2: Porównanie błędu predykcji (RMSE) dla krótkiego i średniego czasu pre-treningu modeli składowych.

6 Wnioski

Przeprowadzony eksperyment potwierdził skuteczność supermodelowania w predykcji układów ekologicznych. Udało mi się pokazać, że nawet przy użyciu niedoskonałych modeli, odpowiednie ich sprężenie (wyuczone na etapie asymilacji danych) pozwala na znaczącą redukcję błędu prognozy w porównaniu do klasycznych metod symulacyjnych. Jakość predykcji jest jednak ściśle skorelowana z jakością wstępnego dopasowania (pre-treningu) modeli składowych.