

1 Cel zadania

Celem laboratorium było zbadanie wrażliwości modelu językowego (LLM) na niewielkie zmiany w warunkach początkowych (promptcie) oraz analiza dynamiki rozbieżności generowanych tekstów. Zjawisko to, analogiczne do efektu motyla w teorii chaosu, sprawdziłem przy użyciu metryk odległości edycyjnej.

2 Metodyka i Narzędzia

Do eksperymentu wykorzystałem lokalnie uruchomiony model `meta-llama/Llama-3.2-3B`. Wybór mniejszego modelu pozwolił na pełną kontrolę nad procesem inferencji oraz parametrami generacji.

2.1 Parametry eksperymentu

- **Model:** Llama-3.2-3B (kwantyzacja/FP16 w zależności od środowiska).
- **Metoda generacji:** Deterministyczna (zachłanna), dzięki czemu symulacja była powtarzalna.
- **Perturbacja:** Zmiana jednego słowa kluczowego w promptcie: *fall* $\leftrightarrow$ *summer*.
- **Kontekst:** Badalem trzy długości promptów (Short, Medium, Long), aby sprawdzić, czy dłuższy kontekst stabilizuje generację.

3 Analiza Wyników

Dla każdej pary wygenerowanych tekstów (zima vs lato) obliczyłem serię odległości Levenshteina $d(k)$, gdzie k to liczba słów. Wyznaczyłem również znormalizowaną dywergencję oraz estymatę wykładnika Lapunowa.

3.1 Przykładowe generacje

Poniżej zamieściłem fragmenty tekstów wygenerowanych dla różnych pór roku, dla różnych długości tekstu wejściowego.

Prompt: On a **season** evening by the harbor, the city lights flickered like patient beacons, and a letter in my pocket felt heavier than paper.

Summer: I was going to ask her to marry me. The idea had come to me while I was driving home from the hospital, where I'd seen a young woman die of a drug overdose. She'd been only twenty-two, and I'd felt a strange, almost physical connection to her, as if she were a part of me...

Fall: I walked slowly, my eyes on the ground, and the world around me seemed to shift into a dream. I could almost believe I was walking through a field of daisies, with the sun on my back and a gentle breeze blowing my hair. The only thing that kept me grounded was the weight of the letter in my pocket. It was a reminder that I was not just walking through a field of daisies; I was walking home...

Prompt: On a **season** evening by the harbor, the city lights flickered like patient beacons, and a letter in my pocket felt heavier than paper. Somewhere out on the water, a horn sounded once, then faded into the hush between waves. I unfolded the crease at the letter's edge and knew, before reading, that it would redraw the map of my small life.

Summer: I had been in New York City only a few days when I first met him. He was tall, and his eyes were brown, and his hair was black. He was not like anyone I'd known before. I didn't know what to do with him, but I liked him. I liked the way he looked at me. I liked the way he said my name. I liked the way he smelled...

Fall: I was not alone in this, for the letters of my childhood, and those of my adolescence, and even the few I'd written, had already done so. The letters I'd written to my mother, and those I'd received in response, had changed me, as if they'd been my first and last words. I was not alone in this, for the letters of my childhood, and those of my adolescence, and even the few I'd written, had already done so. I was not alone in this, for the letters of my childhood, and those of my adolescence, and even the few I'd written, had already done so...

Analogicznie wygenerowałem dopełnienia dla dłuższego tekstu, jednak zdecydowałem się nie zamieścić go w sprawozdaniu (sam tekst nie dodaje specjalnie wartości).

3.2 Wizualizacja metryk

Poniższe wykresy prezentują przebieg rozbieżności tekstów w funkcji liczby wygenerowanych słów.




Figure 1: Wykresy metryk dla trzech długości promptów. Od lewej, (1) znormalizowana dywergencja, (2) odległość Levenshteina, (3) logarytmiczna miara rozbieżności, (4) znormalizowana miara rozbieżności.

4 Wnioski

4.1 Analiza wyników

Analiza wykresów (Rys. 1) prowadzi do następujących obserwacji:

1. **Natychmiastowa dywergencja:** Bardzo mała zmiana promptu (jedno słowo) drastycznie wpływa na generowany tekst. Ścieżki rozjeżdżają się praktycznie natychmiastowo ($k < 5$). Nawet badając same suffixy generowanych wypowiedzi dochodzimy do analogicznych wniosków.

2. **Liniowy wzrost odległości:** Na drugim wykresie widzimy, że odległość Levenshteina rośnie niemal liniowo względem długości tekstu. Oznacza to, że po początkowym rozwinięciu, teksty nie wykazują już żadnej korelacji semantycznej ani strukturalnej.
3. **Brak stabilizacji przez kontekst:** Długość promptu (Short vs Long), pomimo zmniejszenia procentowego udziału perturbacji w całym wejściu, nie stabilizuje trajektorii generacji.

4.2 Potencjalne wyjaśnienie

Prawdopodobnie wynika to z **autoregresywnej natury modelu językowego**. W architekturze Transformer, każdy nowo wygenerowany token staje się częścią kontekstu dla następnego kroku. Wystąpienie pierwszego odmiennego tokenu (spowodowanego zmianą pory roku) zmienia rozkład prawdopodobieństwa dla wszystkich kolejnych kroków. Ponieważ model nie posiada mechanizmu „powrotu” do ustalonej fabuły, błąd ten jest wzmacniany kaskadowo (sprzężenie zwrotne dodatnie), co prowadzi do całkowitej separacji trajektorii semantycznych niezależnie od długości początkowego kontekstu.